健康数据科学课程报告

黄艾萍 | 学号：2510108119

2026 年 4 月

1　个人主页网址

本课程作业的个人主页已经部署在 GitHub Pages，可公开访问，地址为：

`https://zhuzhu-950.github.io/`

2　数据读取

本项目采用临床患者数据集（‘data.xlsx‘），共包含 13258 条患者样本、7 个变量，目标变量为院内死亡状态（‘HOSPITAL_EXPIRE_FLAG‘，0= 存活，1= 死亡）。数据读取结果如下：

```
数据大小: (13258, 7)
<bound method NDFrame.head of        age_month  lab_5237_min  lab_5227_min  lab_5225_range  lab_5235_max  \
0              4           NaN           NaN             NaN           NaN
1             86           NaN           NaN             NaN           NaN
2             34           NaN           NaN             NaN           NaN
3             94           NaN           NaN             NaN           NaN
4             11           NaN           NaN             NaN           NaN
...          ...           ...           ...             ...           ...
13253          8           NaN           NaN             NaN           NaN
13254         98         7.183           2.1            14.3          47.7
13255         16         6.990           2.8             1.4          53.6
13256          3           NaN           NaN             NaN           NaN
13257          6         7.431           1.0             0.0          28.1

       lab_5257_min  HOSPITAL_EXPIRE_FLAG
0               NaN                     0
1               NaN                     1
2               NaN                     0
3               NaN                     1
4               NaN                     1
...             ...                   ...
13253           NaN                     0
13254          84.0                     0
13255         133.0                     0
13256           NaN                     0
13257         103.0                     0

[13258 rows x 7 columns]>
```

图 1: 数据读取结果展示

3 数据预处理

数据预处理包括以下步骤：

1. 缺失值填充：对数据集中的实验室指标缺失值采用均值/中位数填充，保证数据完整性
2. 标准化处理：对连续型特征进行 Z-score 标准化，消除量纲影响
3. 数据集划分：按 7:3 的比例将数据划分为训练集与测试集，用于模型构建与评估

4 预测模型建立

本项目构建了三种二分类模型用于患者院内死亡风险预测：

1. 逻辑回归：作为基线模型，解释性强，可直接输出各特征的回归系数
2. 随机森林：集成学习模型，抗过拟合能力强，可输出特征重要性
3. 支持向量机（SVM）：适用于高维数据，对非线性数据有较好的分类效果

5 前端开发与部署

本课程作业的个人主页基于 GitHub Pages 部署，通过 HTML/CSS 实现了报告的在线展示，地址为：`https://zhuzhu-950.github.io/`

6 统计分布

6.1 目标变量分布分析

数据集中患者结局分布如下图所示，可直观观察存活与死亡样本的比例分布：

```
=== 数据描述性统计 ===
       age_month  lab_5237_min  lab_5227_min  lab_5225_range  lab_5235_max  \
count   13258.00       8668.00       8616.00         8666.00       8671.00
mean       29.99          7.35          2.25            3.84         42.61
std        44.03          0.12          1.82            5.46         14.79
min        -1.00          6.44          0.00            0.00         10.40
25%         1.00          7.31          1.20            0.00         34.20
50%         8.00          7.37          1.80            1.50         39.60
75%        41.00          7.42          2.70            6.00         46.90
max       217.00          7.70         28.00           60.50        217.00

       lab_5257_min  HOSPITAL_EXPIRE_FLAG
count       8662.00              13258.00
mean          91.55                  0.06
std           55.25                  0.24
min           -0.60                  0.00
25%           17.60                  0.00
50%          105.00                  0.00
75%          131.00                  0.00
max          245.00                  1.00

=== 目标变量分布 ===
HOSPITAL_EXPIRE_FLAG
0    12478
1      780
Name: count, dtype: int64
死亡率: 5.88%
```

图 2: 统计分布分析

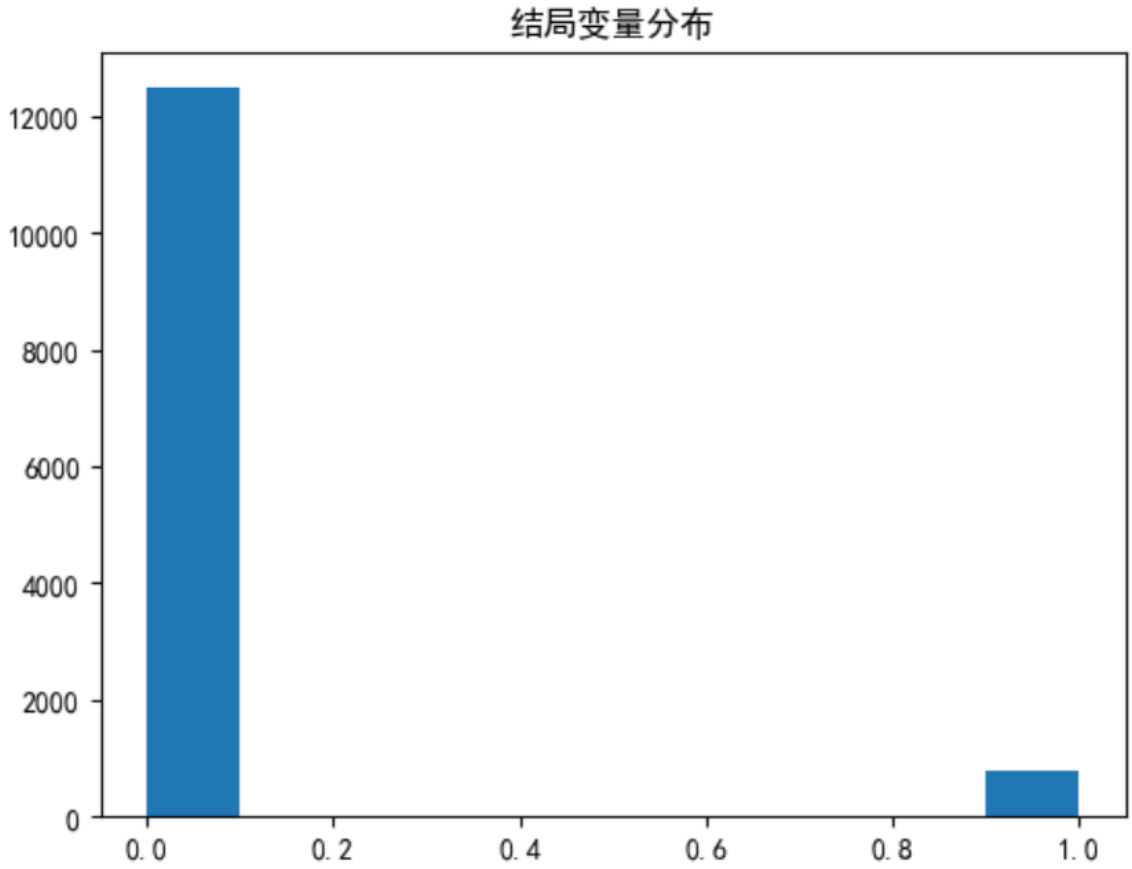

图 3: 患者结局变量分布直方图

6.2 特征重要性分析

随机森林模型输出的特征重要性如下图所示，可直观对比各临床指标对患者死亡风险的影响程度:

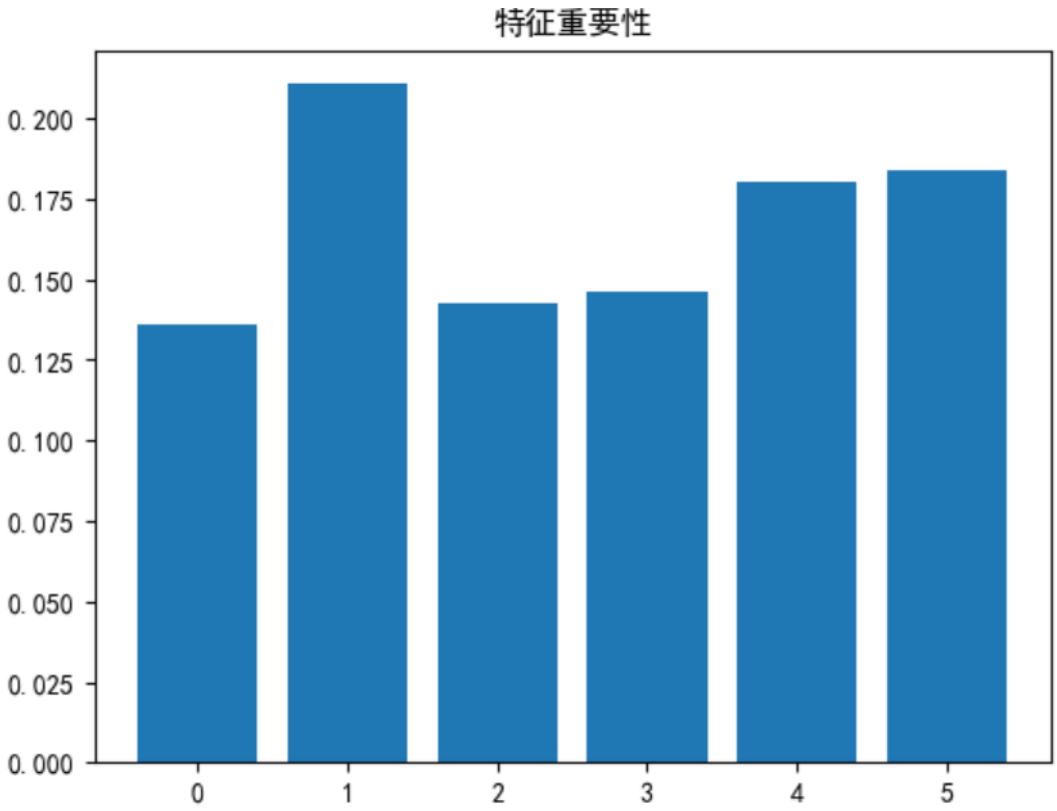

图 4: 特征重要性柱状图

7 数据预处理与模型构建

数据预处理包括缺失值填充、标准化与数据集划分，随后构建三种二分类模型用于患者院内死亡风险预测：逻辑回归、随机森林、支持向量机（SVM）。

8 模型评估与可视化

8.1 模型准确率对比

三种模型在测试集上的准确率对比如下：

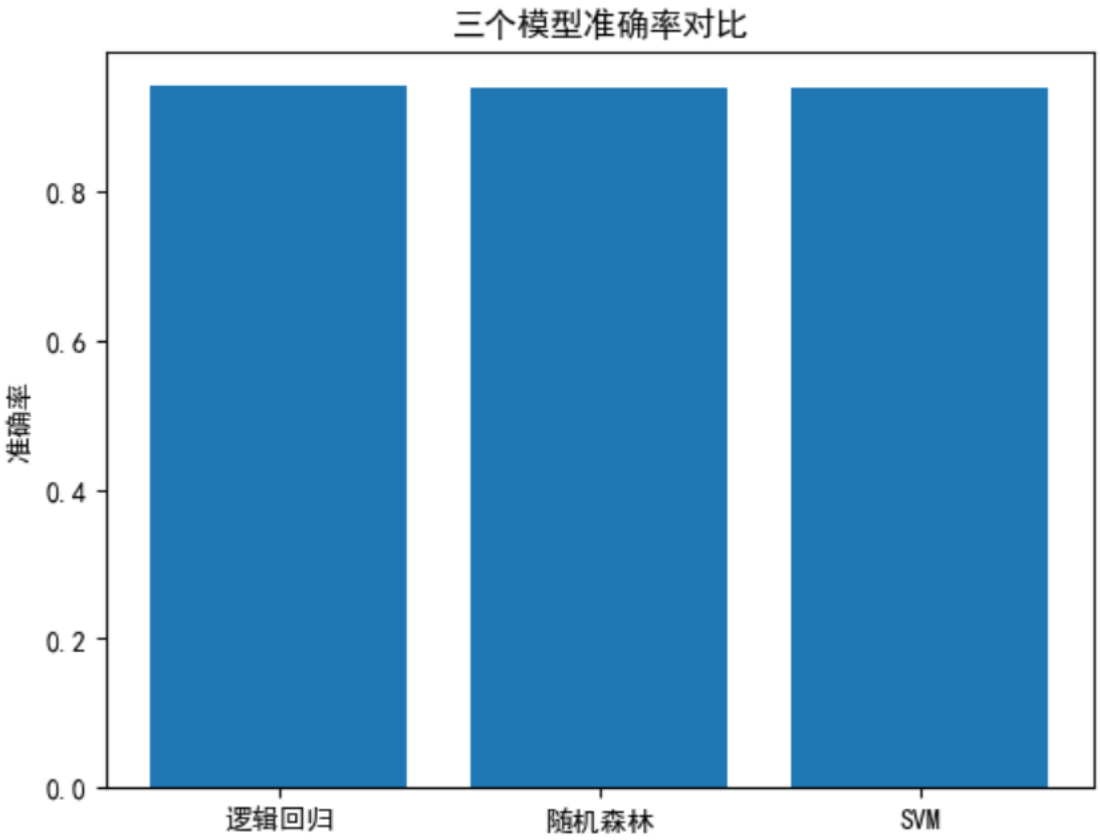

图 5: 三种模型准确率对比柱状图

8.2 ROC 曲线与 AUC 评估

三种模型的 ROC 曲线与 AUC 值如下，可直观对比模型的区分能力：

]

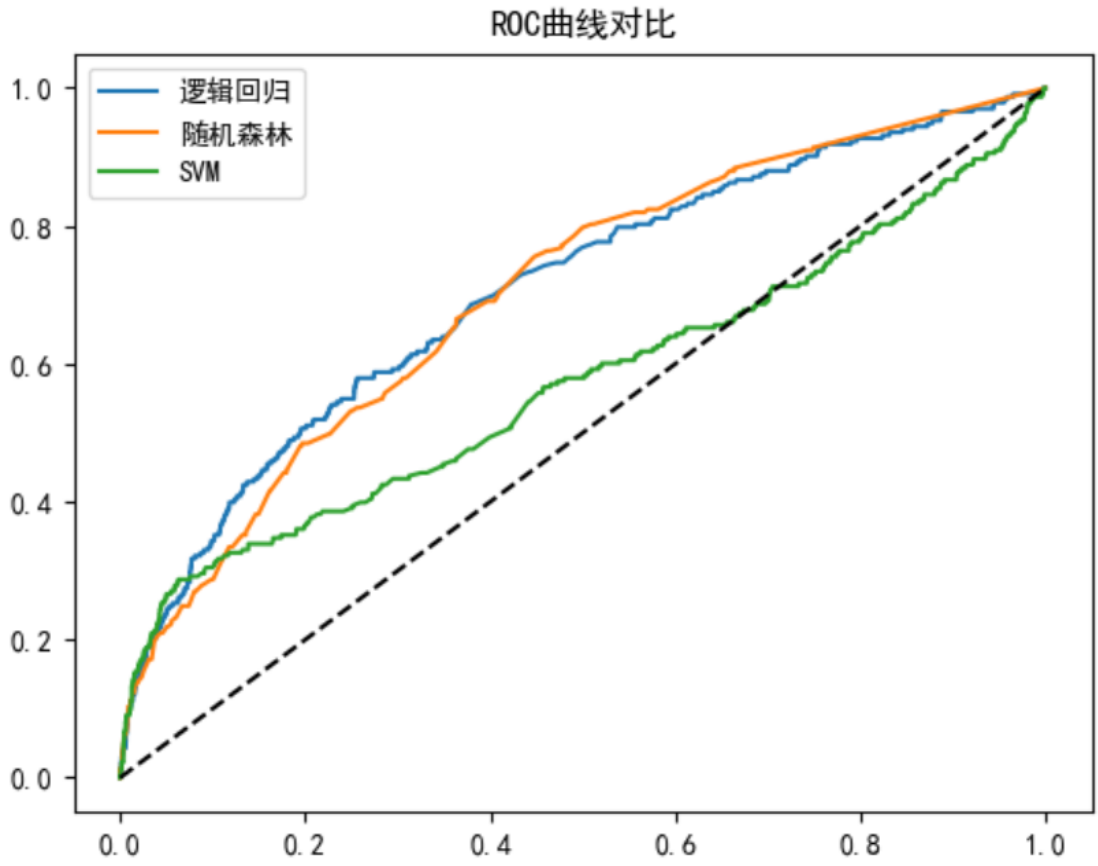

图 6: 三种模型 ROC 曲线对比

9 K-Means 聚类分析

9.1 肘部法确定最优 K 值

通过肘部法确定 K-Means 聚类的最优聚类数:

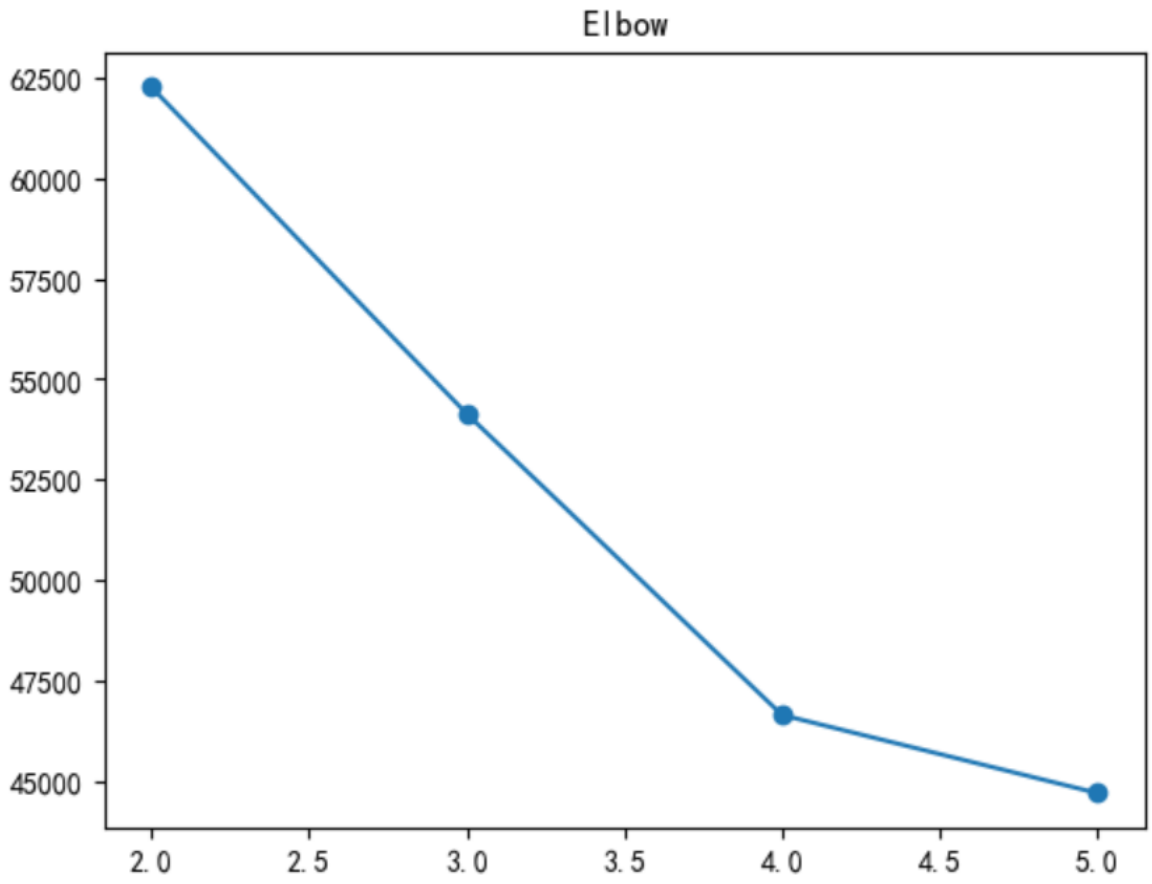

图 7: K-Means 肘部法确定最优 K 值

9.2 聚类结果可视化

基于最优 K 值的 K-Means 聚类结果散点图如下:

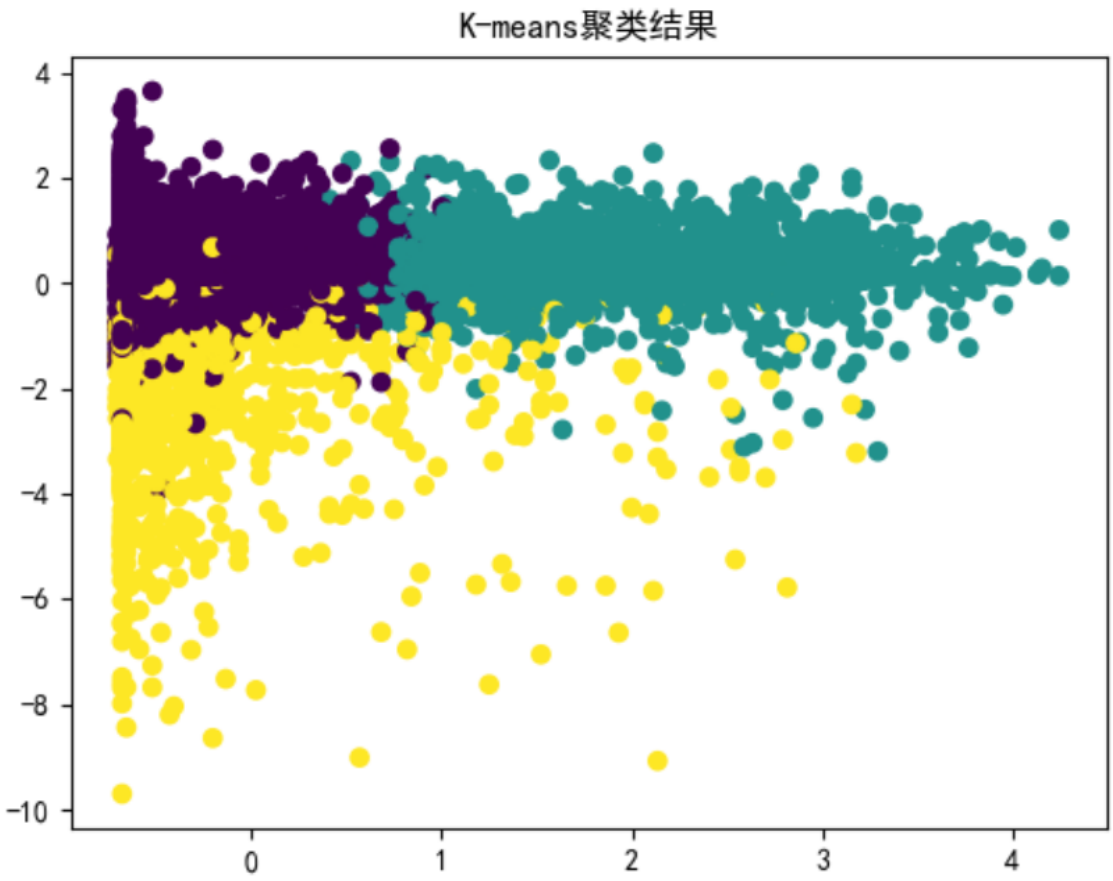

图 8: K-Means 聚类结果散点图